2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 34

Bayones, Santiago

Lopez, Agustin

Massaccesi, Valentin

1. Introducción

La documentación del conjunto de datos lo presenta como:

“El Instituto Nacional de Estadística y Censos (INDEC) conjuntamente con el Ministerio de Salud y Desarrollo Social (MSyDS) realizaron la 4° Encuesta Nacional de Factores de Riesgo (ENFR) en 2018, con el objetivo de proporcionar información válida, confiable y oportuna sobre factores de riesgo (como consumo de tabaco, alcohol, alimentación, actividad física, entre otros), procesos de atención en el sistema de salud y principales enfermedades no transmisibles (ENT) en la población (hipertensión, diabetes, obesidad y otras). Se trata de la cuarta encuesta de este tipo llevada a cabo en el país, las anteriores se desarrollaron en 2005, 2009 y 2013.”

Básicamente, el conjunto de datos son las respuestas,por persona, a esta encuesta realizada en 2018.

Los objetivos de esta encuesta son:

1. Proporcionar información válida, confiable y oportuna sobre factores de riesgo, procesos de atención en el sistema de salud y prevalencias de las principales ENT (hipertensión, diabetes, obesidad y otras) en la población de 18 años y más, residente en viviendas particulares de áreas urbanas de 5.000 y más habitantes de la República Argentina.
2. Monitorear la evolución de los principales factores de riesgo de las ENT.
3. Evaluar el impacto de políticas de prevención y control realizadas a nivel nacional y provincial.
4. Proporcionar parámetros objetivos de los principales factores de riesgo y las ENT a partir de las mediciones físicas y bioquímicas.

Los principales problemas que nos encontramos fueron la cantidad de columnas del dataset (287) y los nombres de estas, que dan poca información sobre de qué se tratan.

El primer problema nos impidió hacer un análisis y limpieza inicial, ya que al ser tantas y no tener un enfoque definido, iba a ser ineficiente ir columna por columna. Lo resolvimos delegando esto a la resolución de cada hipótesis, donde al tener un enfoque en pocas variables (columnas), la limpieza y el análisis se hacía más simple.

El segundo problema lo resolvimos simplemente leyendo el diccionario que trae la documentación, y cambiando los nombres de las columnas a medida que las íbamos usando.

El trabajo está dividido en **5** secciones:

- **0 - Paquetes, dataframe, links:** Importación de paquetes, links usados y definición del dataset.
- **1 - Análisis Exploratorio Inicial:** Presentación,Objetivos de la encuesta, Descripciones de las variables y que representan, consideraciones técnicas.
- **2 - Limpieza de la base:** Explicación de la limpieza de la base
- **3 - Planteo de Hipótesis:** Planteo de las 3 hipótesis pedidas por la cátedra
- **4 - Resolución de Hipótesis:** Resolución de las 3 hipótesis planteadas y las 3 hipótesis dadas por la cátedra

2. Análisis exploratorio de los datos

Como dijimos en la introducción, el tamaño del dataset y la cantidad de datos distintos hacen difícil hacer una análisis exploratorio de los datos. Lo que nos ayudó fue el contexto que nos dio la documentación, que tipos de factores de riesgo, ENT (enfermedades no transmisibles) y que datos les pedían a los encuestados. Gracias a esto, nos pareció oportuno dejar el análisis de datos para cuando resolvamos las hipótesis, y armar estas usando el contexto de la encuesta.

Los datos que nos parecieron interesantes fueron:

- Quintil de hogares según ingreso por unidad consumidora
- Nivel de educación de la persona encuestada
- Nivel de actividad física
- Condicion de Fumador
- Promedio de las dos últimas mediciones de tensión sistólica
- Índice de masa corporal por autorreporte
- Consumo regular de riesgo de alcohol
- Consumo de al menos cinco porciones diarias de frutas o verduras
- Habitualmente, ¿le agrega sal a las comidas durante la cocción?

A partir de estas armamos las hipótesis.

3. Hipótesis y resolución

3.1. Hipótesis 1:

3.1.1. Definición de la hipótesis

La hipótesis planteada por nosotros para la univariada fue que la mayoría de los adultos argentinos que probaron cigarrillos iniciaron su consumo durante la adolescencia (entre los 13 y 18 años).

La motivación es que identificar en qué momento de la vida se inicia el acercamiento al tabaco es muy importante para la salud pública y conocer esta distribución podría ayudar a definir en qué franja de edad se pueden centrar las campañas educativas de concientización para evitar la adquisición temprana del hábito.

3.1.2. Estrategia de abordaje

La variable utilizada fue `bita02` (Cuantitativa Discreta: Edad en años cumplidos al probar o empezar a fumar por primera vez).
Para el preprocesamiento se filtraron los datos nulos, acotando el análisis para la población de encuestados que declararon haber probado cigarrillos alguna vez.

Se aplicaron métricas de resumen univariado mediante la función `.describe()` (evaluando media, mediana, desviación estándar y cuartiles Q1 y Q3). Para la visualización se utilizó un **histograma de frecuencias** (mediante la herramienta Sweetviz) destacando la franja de edad de 13 a 18.

Los cálculos estadísticos y la generación del gráfico se ejecutan en la celda:
"4-Validación de Hipótesis"
"Univariada"

3.1.3. Resultados obtenidos y discusión

Métricas descriptivas principales:

- **Mediana:** 16 años.
- **Moda (edad más frecuente):** 15 años.
- **Primer cuartil (Q1):** 15 años.
- **Tercer cuartil (Q3):** 18 años.

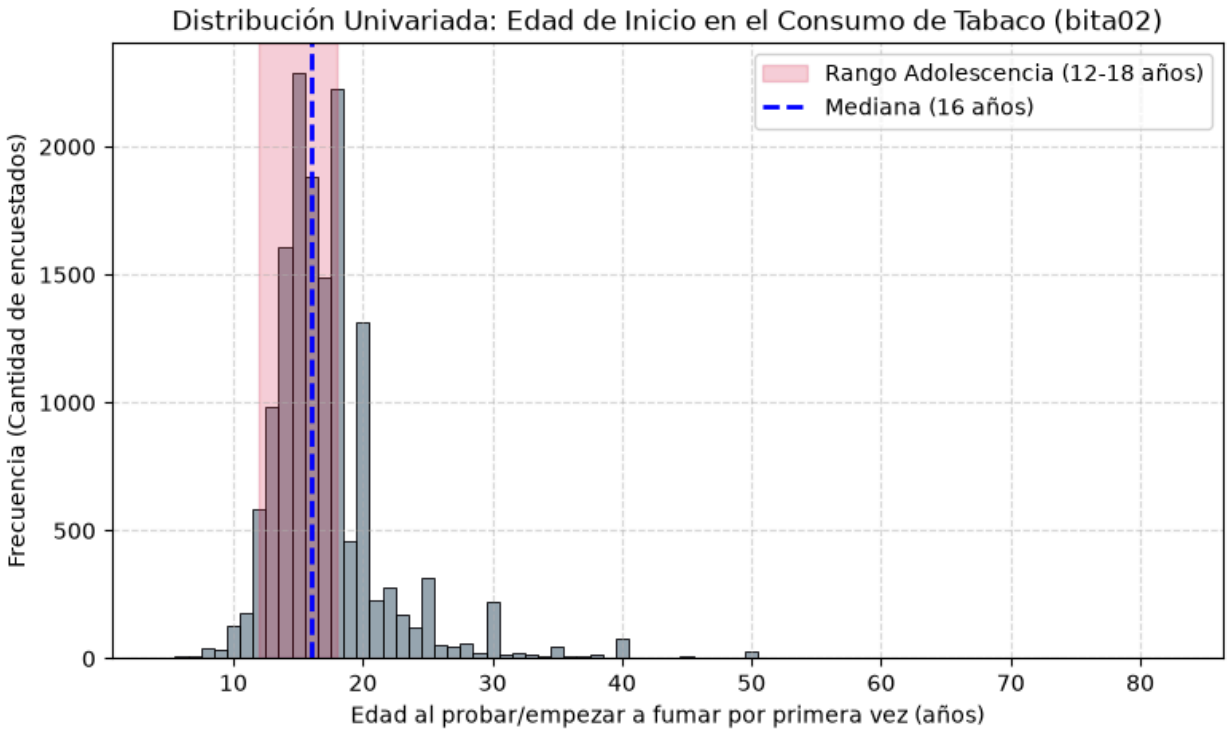


Fig. 1:

La hipótesis planteada resultó **verosímil**.

Los resultados confirman que el inicio de consumo de tabaco en Argentina se encuentra fuertemente concentrado en la adolescencia. Al observar que el **75%** de los consumidores (Q3) comenzó a fumar a los **18 años o antes**, y que la moda se ubica en los **15 años**, se evidencia que la etapa donde se inicia es en fase escolar secundaria.
Esto demuestra que las estrategias de salud pública deberían enfocarse prioritariamente en la prevención primaria y secundaria durante la adolescencia temprana.

3.2. Hipótesis 2:

3.2.1. Definición de la hipótesis

La hipótesis planteada por nosotros para la bivariada fue que a mayor frecuencia de agregado de sal a las comidas después de cocinadas, mayor es el valor de la presión arterial sistólica medida en la población adulta.

La motivación es que la hipertensión arterial constituye uno de los principales factores de riesgo cardiovascular a nivel global. Evaluar la relación entre el hábito declarado del uso de sal de mesa y las mediciones físicas objetivas de presión arterial (obtenidas en el Paso 2 de la encuesta) es

de gran utilidad en salud pública para determinar si la conducta percibida sobre el consumo de sodio impacta directamente en los valores de tensión o si existen sesgos de comportamiento en los encuestados.

3.2.2. Estrategia de abordaje

Las variables utilizadas fueron:

- **bial02** (Cualitativa Ordinal: Frecuencia de agregado de sal a las comidas; 1 = Siempre, 2 = Raras veces, 3 = Nunca).
- **Promedio_sistolica** (Cuantitativa Continua: Presión arterial sistólica promedio registrada en las mediciones físicas en mm/Hg).

Para el preprocesamiento se filtraron los datos nulos.

Se calculó el coeficiente de correlación de Spearman **(r_s)** debido a la naturaleza de **bial02** cruzada con la de **promedio_sistolica**. Para la visualización se empleó un diagrama **Boxplot**, el indicado cuando utilizamos una variable cualitativa y otra cuantitativa, para ver la mediana y promedios de la presión arterial entre los tres niveles de agregado de sal.

Los cálculos estadísticos y la generación del gráfico se ejecutan en la celda:
“4-Validación de Hipótesis”
“Bivariada”

3.2.3. Resultados obtenidos y discusión

Métricas estadísticas:

- **Coeficiente de correlación de Spearman (r_s):** 0.082
- **Presión arterial sistólica promedio por categoría:**
  - **Siempre (1):** 126.79 mm/Hg.
  - **Raras veces (2):** 129.13 mm/Hg.
  - **Nunca (3):** 131.91 mm/Hg.

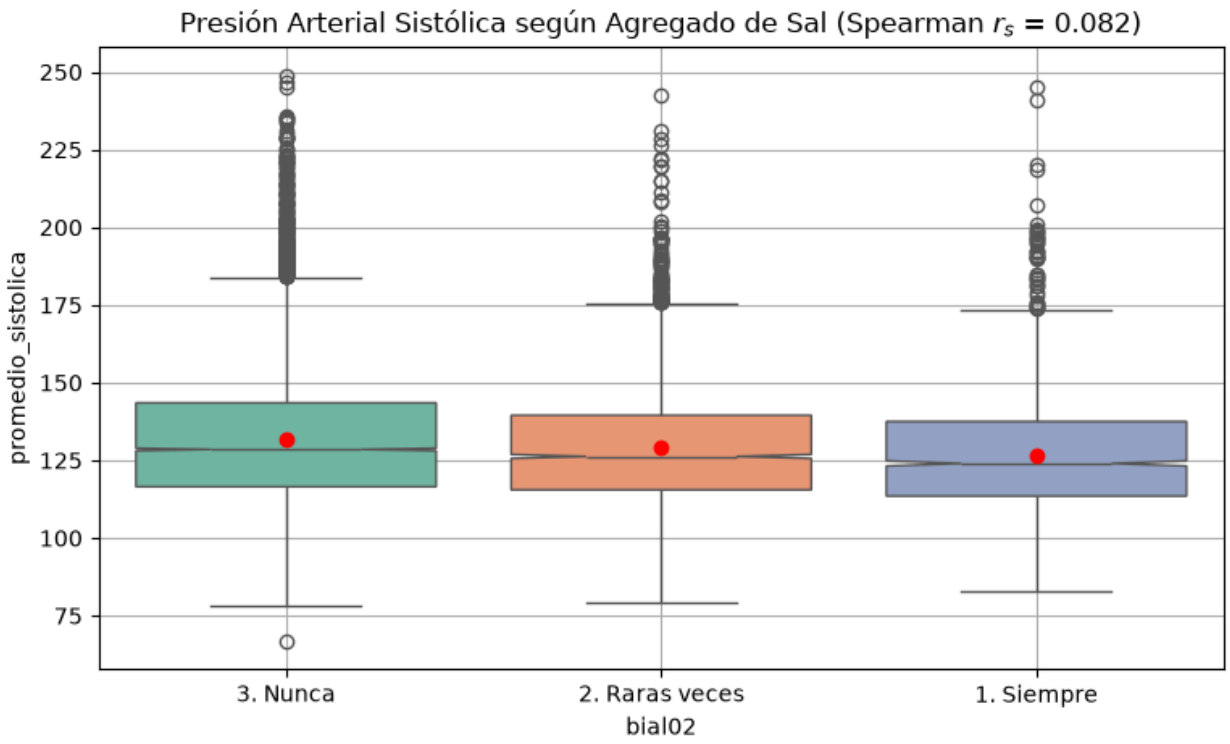


Fig. 2:

La hipótesis planteada resultó **inverosímil**.

Aunque fisiológicamente el consumo elevado de sal tiende a incrementar la presión arterial, la correlación positiva demuestra que las personas que afirman "**Nunca**" agregar sal presentan una presión sistólica promedio más alta **(131.91 mm/Hg)**, mientras que quienes agregan "**Siempre**" registran los valores más bajos **(126.79mm/Hg)**.
Este hallazgo contraintuitivo se puede explicar por un sesgo de diagnóstico previo: aquellas personas ya diagnosticadas con hipertensión o que sufren de presión alta han recibido indicaciones médicas estrictas para eliminar el agregado de sal de su dieta (*quienes respondieron "Nunca"*), mientras que el resto no percibe la necesidad de restringir el sodio. Esto muestra las limitaciones de analizar el consumo de sal únicamente mediante un autoreporte sin controlar por antecedentes médicos.

3.3. Hipótesis 3:

3.3.1. Definición de la hipótesis

"A menor nivel socioeconómico (ingreso del hogar y nivel de instrucción), mayor acumulación de factores de riesgo (tabaquismo, consumo regular de riesgo de alcohol, sedentarismo, obesidad y bajo consumo de frutas y verduras), controlando por sexo, edad y región."

Esta hipótesis nos parece útil, ya que permite ver que tipo de personas son las más vulnerables a estos riesgos.

3.3.2. Estrategia de abordaje

Las variables utilizadas fueron:

Variable	Variable en la base	Construcción
Quintil de ingreso	`quintil_uc`	1 (más bajo) a 5 (más alto), ingreso por unidad consumidora; se trata como numérica
Instrucción	`nivel_instruccion_agrupado`	1 hasta primario incompleto, 2 hasta secundario incompleto, 3 secundario completo y más (referencia)
Sexo	`bhch03`	1 varón (referencia), 2 mujer
Edad	`rango_edad`	18-24 (referencia), 25-34, 35-49, 50-64, 65 y más
Región	`region`	Metropolitana (referencia), Pampeana, Noroeste, Noreste, Cuyo, Patagónica
Fumador actual	`consumo_tabaco_100`	1 si es fumador actual; ex fumadores y no fumadores = 0
Alcohol de riesgo	`consumo_regular_riesgo`	1 si tiene consumo regular de riesgo
Sedentarismo	`nivel_actividad_fisica`	1 si el nivel de actividad física es bajo
Obesidad	`imc_categorias`	1 si IMC autorreportado ≥ 30
Bajo consumo de frutas y verduras	`consumo_fv`	1 si no llega a 5 porciones diarias
Ponderador	`wf1p`	Factor de expansión del cuestionario

Fig. 3:Variables Utilizadas

Y se usó el siguiente método:

1. Estadísticos descriptivos ponderados con **wf1p**.
2. **Modelo 1**: regresión lineal ponderada del índice sobre el quintil de ingreso, sin controles.
3. **Modelo 2:** igual, agregando instrucción, sexo, edad y región.
4. **Modelo 3:** regresión logística de tener 3 o más factores, con los mismos controles (odds ratios).
5. **Modelo 4:** una regresión logística por cada factor, para ver cuáles explican el resultado.

Todos los modelos usan el ponderador normalizado (media 1) y errores estándar robustos (HC1).

Se eliminaron 3230 casos que tenían NaN en alguna variable, por lo cual muestra quedó de **25.994** personas.

Luego, como está en la tabla, las variables se transforman a 0 y 1 (chequear tabla para ver las consideraciones).

Se crean dos columnas más:

- **n_factores:** es la suma de los cinco factores (0 a 5).
- **peso_norm:** es wf1p dividido por su promedio, para que los pesos tengan media 1 y los modelos no crean que tienen millones de casos.

```
Casos iniciales: 29224 | casos completos: 25994 (3230 descartados por datos faltantes)
   quintil_ingreso  instruccion  sexo  edad  region  peso  fuma  \
0                5            3     1     2       1  2378   0.0
1                5            3     2     5       1  3588   0.0
2                5            3     2     2       1  2740   0.0
3                5            3     2     4       1   493   1.0
4                5            3     1     1       1  2016   0.0

   alcohol_riesgo  sedentarismo  obesidad  poco_fv  n_factores  peso_norm
0             0.0           0.0       1.0      1.0         2.0   2.465392
1             0.0           0.0       0.0      0.0         0.0   3.719860
2             0.0           0.0       0.0      1.0         1.0   2.840696
3             0.0           1.0       0.0      1.0         3.0   0.511118
4             0.0           0.0       0.0      1.0         1.0   2.090089
```

Fig. 4: Head del dataset creado

Luego calculamos promedios ponderados con `np.average(x, weights=pesos)`:

- La prevalencia de cada factor
- La distribución del índice
- El promedio de factores y las prevalencias por quintil y por nivel de instrucción.

También calculamos la correlación entre quintil e instrucción para ver si medían lo mismo.

Los descriptivos muestran:

- El promedio es de 1,93 factores por persona. El sedentarismo (43,2%) y el bajo consumo de frutas y verduras (93,9%) son los más frecuentes.
- El promedio de factores casi no cambia entre los quintiles 1 y 3 (2,01; 2,02; 1,98) y recién baja en los quintiles 4 y 5 (1,87; 1,77), de modo que la relación no es estrictamente lineal.
- Por instrucción: 2,13 (hasta primario incompleto), 2,09 (hasta secundario incompleto) y 1,81 (secundario completo y más).

- Quintil e instrucción están moderadamente correlacionados (Spearman = 0,32), por lo que aportan información parcialmente distinta.

Luego armamos la matriz de variables para los modelos

La función `matriz_diseno` transforma las variables en columnas numéricas:

- El quintil queda como número (1 a 5), así el coeficiente se lee como “efecto por cada quintil”.
- Instrucción, edad y región son categorías, y con `pd.get_dummies` cada una se convierte en columnas 0/1 (una por categoría). A cada variable se le sacó una categoría, que es la referencia contra la que se compara: instrucción “secundario completo y más”, edad 18-24 y región Metropolitana.

Con esta matriz, se calculan los modelos anteriormente mencionados:

```
=== Modelo 1: n_factores ~ quintil (sin controles) ===
                   coef  error_std        z    p  IC95_inf  IC95_sup
const            2.1224     0.0250  84.8761  0.0    2.0734    2.1714
quintil_ingreso -0.0641     0.0071  -9.0345  0.0   -0.0780   -0.0502

=== Modelo 2: n_factores ~ quintil + instrucción + sexo + edad + región ===
                   coef  error_std        z       p  IC95_inf  IC95_sup
const            1.7725     0.0448  39.5765  0.0000    1.6847    1.8603
quintil_ingreso -0.0489     0.0078  -6.2706  0.0000   -0.0642   -0.0336
mujer           -0.0861     0.0195  -4.4251  0.0000   -0.1243   -0.0480
instr_1          0.2519     0.0426   5.9095  0.0000    0.1683    0.3354
instr_2          0.2192     0.0227   9.6442  0.0000    0.1747    0.2638
edad_2           0.2172     0.0344   6.3136  0.0000    0.1498    0.2847
edad_3           0.3169     0.0328   9.6604  0.0000    0.2526    0.3812
edad_4           0.3184     0.0337   9.4522  0.0000    0.2524    0.3844
edad_5           0.1978     0.0346   5.7119  0.0000    0.1300    0.2657
region_2         0.0557     0.0251   2.2191  0.0265    0.0065    0.1049
region_3         0.0617     0.0274   2.2507  0.0244    0.0080    0.1154
region_4        -0.0366     0.0285  -1.2824  0.1997   -0.0925    0.0193
region_5         0.0067     0.0326   0.2063  0.8365   -0.0571    0.0705
region_6         0.0934     0.0285   3.2752  0.0011    0.0375    0.1492
```

Fig. 5:Resultados modelo 1 y 2

```
=== Modelo 3: logit de tener 3 o más factores (odds ratios) ===
                    OR  OR_inf  OR_sup       p
const           0.2489  0.1957  0.3164  0.0000
quintil_ingreso 0.9067  0.8705  0.9443  0.0000
mujer           0.7548  0.6823  0.8350  0.0000
instr_1         1.7636  1.4238  2.1845  0.0000
instr_2         1.5683  1.3958  1.7620  0.0000
edad_2          1.6383  1.3351  2.0104  0.0000
edad_3          1.9810  1.6394  2.3939  0.0000
edad_4          1.9358  1.5910  2.3553  0.0000
edad_5          1.4792  1.2000  1.8232  0.0002
region_2        1.1131  0.9763  1.2692  0.1094
region_3        1.0289  0.8897  1.1900  0.7005
region_4        0.8386  0.7177  0.9798  0.0267
region_5        0.9132  0.7619  1.0945  0.3258
region_6        1.2068  1.0434  1.3957  0.0113
```

Fig. 6: Resultados modelo 3

```
=== Modelo 4: un logit por factor (OR de quintil e instrucción) ===
        factor        variable     OR  OR_inf  OR_sup      p
         fuma quintil_ingreso 0.9653  0.9254  1.0070 0.1015
         fuma         instr_1 1.2420  0.9790  1.5757 0.0743
         fuma         instr_2 1.4820  1.3072  1.6802 0.0000
alcohol_riesgo quintil_ingreso 1.0261  0.9627  1.0937 0.4286
alcohol_riesgo         instr_1 1.0960  0.7744  1.5512 0.6049
alcohol_riesgo         instr_2 1.0464  0.8735  1.2536 0.6222
  sedentarismo quintil_ingreso 0.9249  0.8929  0.9581 0.0000
  sedentarismo         instr_1 1.5630  1.2904  1.8932 0.0000
  sedentarismo         instr_2 1.3542  1.2219  1.5009 0.0000
     obesidad quintil_ingreso 0.8945  0.8585  0.9321 0.0000
     obesidad         instr_1 1.4562  1.1768  1.8020 0.0005
     obesidad         instr_2 1.3674  1.2155  1.5382 0.0000
      poco_fv quintil_ingreso 0.8910  0.8289  0.9578 0.0018
      poco_fv         instr_1 1.5526  1.0352  2.3286 0.0334
      poco_fv         instr_2 1.3733  1.1177  1.6874 0.0025
```

Fig. 7: Resultados modelo 4

3.3.3. Resultados obtenidos y discusión

Resultados de los modelos:

- **Modelo 1 (sin controles):** Cada quintil adicional de ingreso se asocia con 0,064 factores menos (IC 95%: −0,078 a −0,050; p < 0,001).
- **Modelo 2 (con controles):** El efecto del ingreso se mantiene pero se reduce: −0,049 factores por quintil (IC 95%: −0,064 a −0,034; p < 0,001), unos 0,2 factores menos entre el quintil 5 y el 1. La instrucción tiene un efecto propio, independiente del ingreso: respecto de quienes completaron el secundario, tener hasta primario incompleto suma +0,25 factores (IC 95%: 0,17 a 0,34) y hasta secundario incompleto +0,22 (IC 95%: 0,17 a 0,26). Las mujeres tienen 0.09 factores menos que los varones. Respecto de los 18 a 24 años, el índice es mayor en todos los tramos y alcanza su máximo entre los 35 y 64 años (+0,32). Por región, Patagónica (+0,09), Noroeste (+0,06) y Pampeana (+0,06) superan a la Metropolitana; Noreste y Cuyo no difieren significativamente.
- **Modelo 3 (3 o más factores):** Por cada quintil que sube el ingreso, las chances de acumular 3 o más factores bajan alrededor de un 9% (OR = 0,91; IC 95%: 0,87 a 0,94). Tener hasta primario incompleto multiplica las chances por 1,76 (IC 95%: 1,42 a 2,18) y hasta secundario incompleto por 1,57 (IC 95%: 1,40 a 1,76), respecto de secundario completo y más. Las mujeres tienen menos chances que los varones (OR = 0,75).
- **Modelos 4 (un modelo por factor):** El ingreso se asocia de forma significativa con **sedentarismo**(OR = 0,92 por quintil), **obesidad**(0,89) y **bajo consumo de frutas y verduras** (0,89). No se asocia significativamente con el **tabaquismo** (0,97; IC 95%: 0,93 a 1,01), que sí se relaciona con la instrucción (hasta secundario incompleto: OR = 1,48), ni con el **alcohol de riesgo** (1,03; IC 95%: 0,96 a 1,09), que no muestra ningún gradiente.

Con estos resultados, podemos armar los siguientes gráficos:

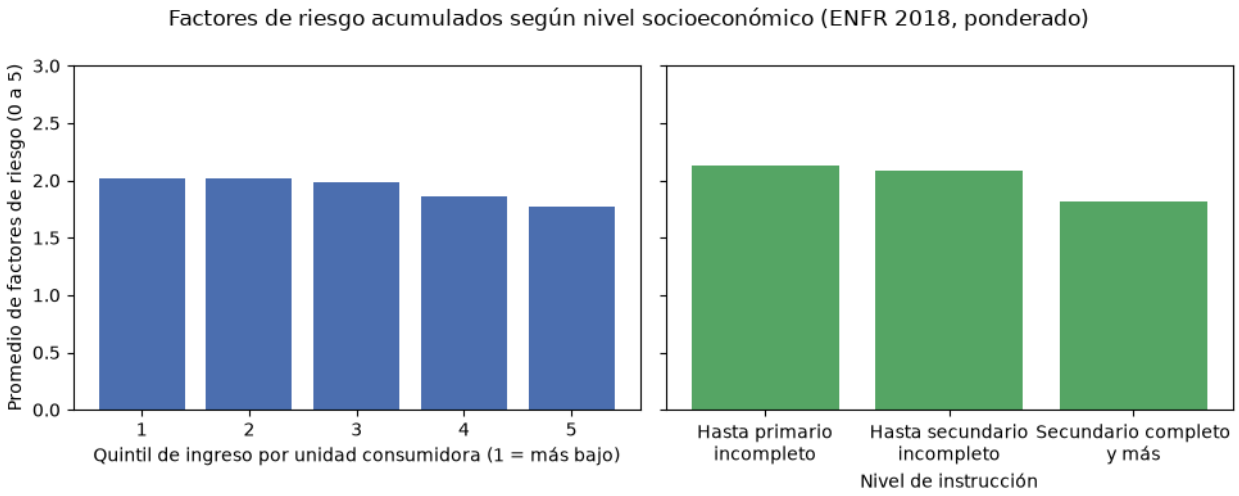


Fig. 8:Factores de riesgo acumulados segun nivel socioeconomico

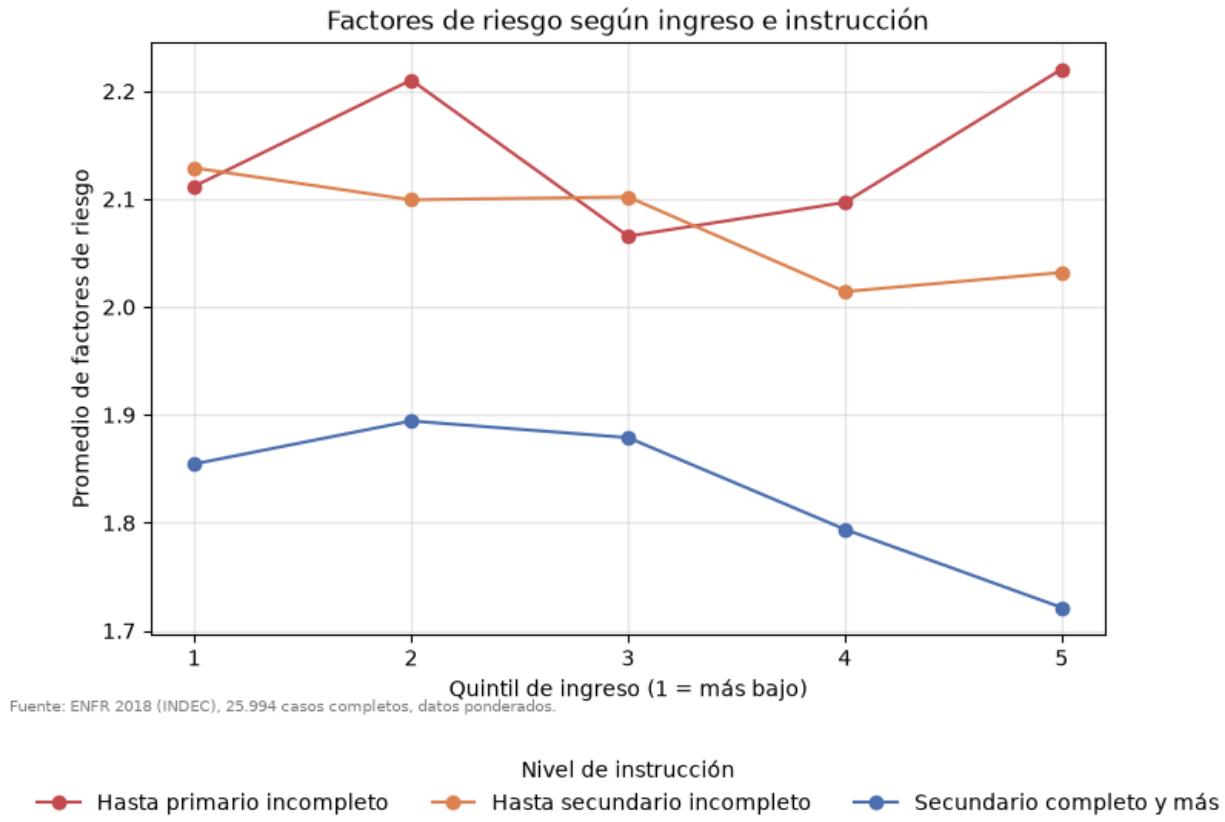


Fig. 9: Factores de riesgo según ingreso e instrucción

La hipótesis se confirma **parcialmente**. Existe un gradiente socioeconómico en la acumulación de factores de riesgo: a mayor ingreso y a mayor nivel de instrucción, menos factores, y ambos efectos se mantienen cuando se controla por el otro y por sexo, edad y región. Sin embargo, ese gradiente se explica por tres factores (sedentarismo, obesidad y bajo consumo de frutas y verduras). El tabaquismo no muestra relación significativa con el ingreso una vez controlado el resto (solo con la instrucción) y el alcohol de riesgo no presenta gradiente alguno, lo que coincide con lo observado en el análisis bivariado inicial. El tamaño del efecto es moderado: la diferencia de ingreso entre el quintil 5 y el 1 equivale a unos 0,2 factores sobre un promedio de 1,9.

Limitaciones a tener en cuenta:

- La encuesta es transversal: muestra asociaciones, no causalidad (por ejemplo, la mala salud también puede reducir el ingreso).
- Sedentarismo, IMC y consumo de frutas y verduras son autorreportados.
- Un 94% de la población no llega a 5 porciones diarias de frutas y verduras, por lo que ese componente casi no discrimina y aporta poca variación al índice.
- Los resultados valen solo para la población adulta (18 años o más).

3.4. Hipótesis 4:

3.4.1. Definición de la hipótesis

La hipótesis, dada por la cátedra, para la univariada es que el consumo diario de frutas y verduras en la población adulta argentina es inferior a las 5 porciones diarias recomendadas por la OMS.

La motivación es que el consumo insuficiente de frutas y verduras es reconocido mundialmente por la OMS como uno de los principales factores de riesgo atribuibles a la mortalidad por enfermedades no transmisibles. Evaluar cuantitativamente este hábito en la población argentina permite diagnosticar la magnitud del déficit nutricional a nivel nacional.

3.4.2. Estrategia de abordaje

La variable utilizada fue **promedio_fv_diario** (Cuantitativa Continua: Cantidad promedio de porciones de frutas y verduras consumidas al día por persona).
Para el preprocesamiento se filtraron los datos nulos.

Se realizó un análisis descriptivo mediante la función **.describe()** para calcular la media, mediana, desviación estándar y cuartiles. Adicionalmente, se calculó la proporción de encuestados que no alcanzan el umbral de 5 porciones diarias. Para la visualización se utilizó un **histograma** trazando una línea de referencia vertical en el valor de corte normativo de la OMS (*5 porciones*).

Los cálculos estadísticos y la generación del gráfico se ejecutan en la celda:
“4-Validación de Hipótesis”
“Univariada”

3.4.3. Resultados obtenidos y discusión

Métricas descriptivas:

- **Promedio:** 2.0 porciones diarias
- **Mediana:** 1.64 porciones diarias.
- **Desviación estándar:** 1.7 porciones.

Evaluación del umbral de la OMS:

- **Porcentaje que consume MENOS de 5 porciones diarias:** 93.8% de la población.
- **Porcentaje que cumple o supera la meta:** 6.2% de la población.

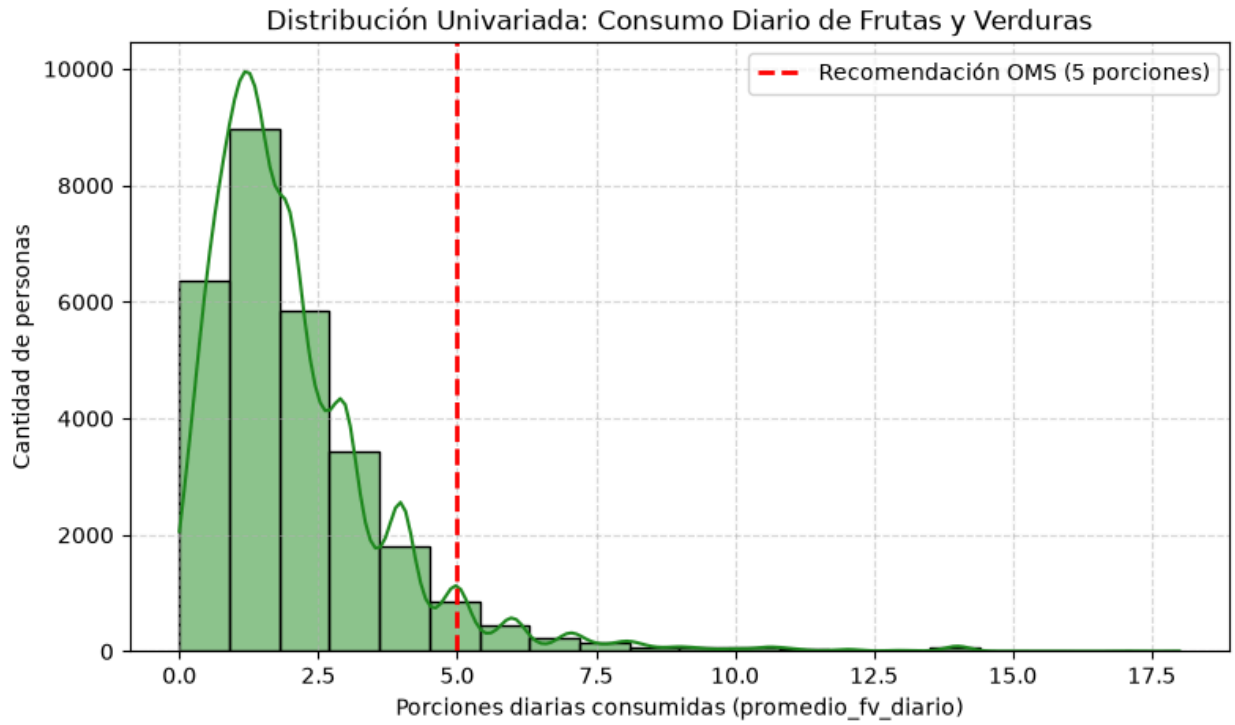


Fig. 10: Histograma de porción diaria promedio de frutas y verduras

La hipótesis planteada resultó **verosímil**.

Los datos de la ENFR respaldan de gran manera la hipótesis de la cátedra. La población adulta argentina consume en promedio apenas **2 porciones diarias** de frutas y verduras, situándose a menos de la mitad de la meta mínima recomendada internacionalmente. El hecho de que **casi el 94%** de los encuestados no alcance dicha recomendación demuestra un problema en los hábitos alimenticios a nivel nacional.

3.5. Hipótesis 5:

3.5.1. Definición de la hipótesis

La hipótesis, dada por la cátedra, para la bivariada es que el índice de masa corporal cambia según el nivel de actividad física de las personas.

La motivación es que el sedentarismo y el exceso de peso representan dos de los factores de riesgo metabólicos y conductuales más prevalentes en la salud pública contemporánea. Evaluar la relación entre la actividad física y el índice de masa corporal (IMC) medido en el Paso 2 de la

encuesta permite verificar si el nivel de inactividad física impacta directamente en el aumento de la masa corporal en la población argentina.

3.5.2. Estrategia de abordaje

Las variables utilizadas fueron:

- **imc_bima** (Cuantitativa Continua: Índice de Masa Corporal medido en kg/m^2).
- **Nivel_actividad_fisica** (Cualitativa Ordinal: Nivel de actividad física categorizada en 1 = Alto, 2 = Medio, 3 = Bajo)

Para el preprocesamiento se filtraron los datos nulos.

Se calculó el coeficiente de correlación de Spearman **(r_s)** debido al carácter ordinal de la variable de **nivel_actividad_física** cruzada con la de **imc_bima**. Adicionalmente, se calcularon los promedios poblacionales de IMC para cada una de las tres categorías de actividad física. Para la visualización se utilizó un diagrama **BoxPlot**.

“4-Validación de Hipótesis”

“Univariada”

3.5.3. Resultados obtenidos y discusión

Métricas estadísticas:

- **Coeficiente de correlación de Spearman (r_s):** 0.129
- **Promedio de IMC(kg) según nivel de actividad física:**
  - **Nivel Alto (1):** 26.95 kg/m^2.
  - **Nivel Medio (2):** 27.82 kg/m^2.
  - **Nivel Bajo (3):** 28.98 kg/m^2.

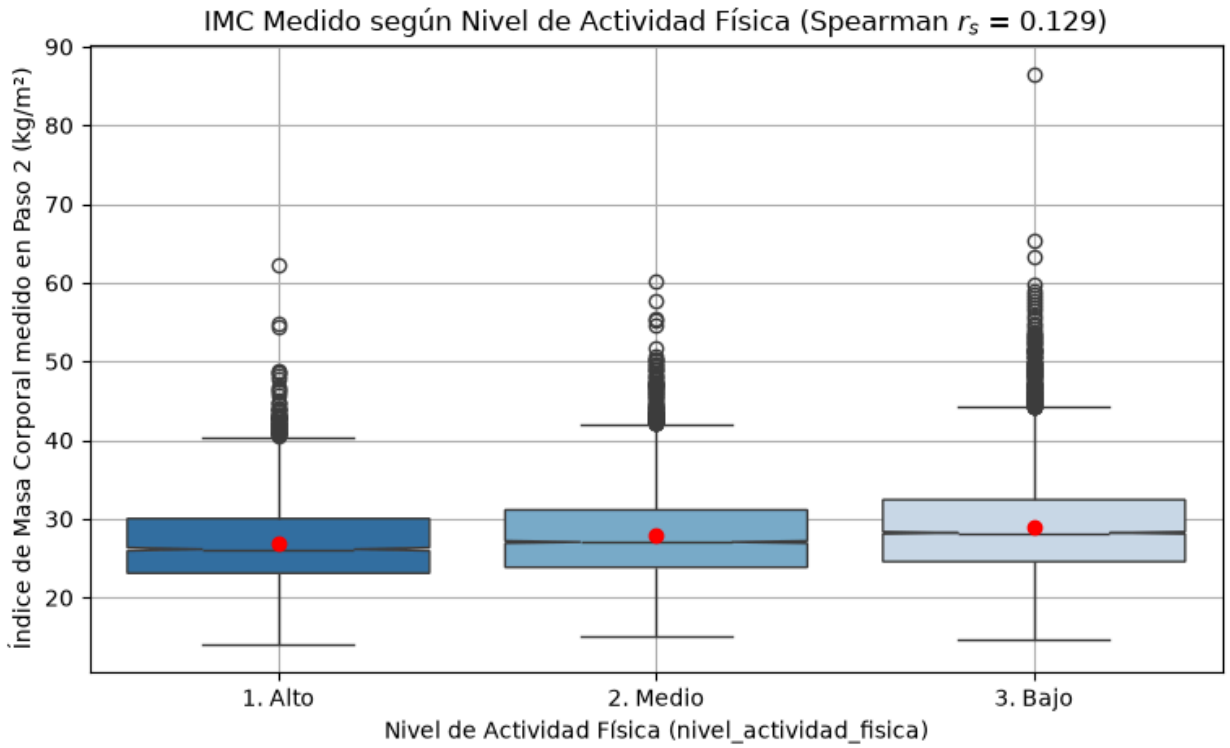


Fig. 11: Box Plots de IMC por nivel de actividad de actividad física

La hipótesis planteada resultó **verosímil**.

Los datos de la ENFR confirman que existe una variación progresiva del índice de masa corporal en función del nivel de actividad física de la población. A medida que se incrementa la escala de inactividad (*1 = Alto → 2 = Medio → 3 = Bajo*), el IMC promedio aumenta de forma directa, pasando de **26.95 kg/m²** en el nivel alto, a **27.82 kg/m²** en el medio y alcanzando su valor máximo de **28.98 kg/m²** en las personas con nivel bajo de actividad física.
Demostrando que a menor actividad física hay un mayor IMC en la población argentina.

3.6. Hipótesis 6:

3.6.1. Definición de la hipótesis

La sexta hipótesis, dada por la cátedra, es “Existe una relación lineal entre el índice de masa corporal, la presión sistólica, el perímetro de la cintura, la edad y los valores de glucemia capilar registrada en ayunas.”

3.6.2. Estrategia de abordaje

Las variables utilizadas fueron:

- **imc_bima** (Cuantitativa Continua: Índice de Masa Corporal medido en kg/m^2).
- **promedio_sistolica** (Cuantitativa Continua: Media de las 3 mediciones de presión sistólica tomadas en el paso 2, medida en mmHg)
- **bima13** (Cuantitativa Continua: Perímetro de la cintura medido en el paso 2, medido en cm)
- **bhch04** (Cuantitativa Discreta: Edad del encuestado, medida en años)
- **bimq05**(Cuantitativa Continua: Nivel de glucosa registrada en el paso 3, medida en mg/dl)

Como estos nombres no son significativos, las variables fueron renombradas **imc, presion, perimetro_cintura, edad y glucosa_registrada**

```
------------------------------
Descripcion de las variables
------------------------------
                imc      presion  perimetro_cintura         edad  \
count  5039.000000  5039.000000        5039.000000  5039.000000
mean     28.191177   129.946616          92.170867    46.246081
std       5.861351    20.893749          16.011371    17.923987
min      15.820000    67.000000          49.000000    18.000000
25%      24.010000   115.000000          81.000000    31.000000
50%      27.360000   126.500000          92.000000    44.000000
75%      31.460000   141.000000         102.000000    60.000000
max      65.310000   245.000000         209.000000    97.000000

       glucosa_registrada
count         5039.000000
mean            80.763247
std             30.860160
min             20.000000
25%             65.000000
50%             79.000000
75%             92.000000
max            382.000000
```

Fig. 12: Descripción de las variables utilizadas

Para validar esta hipótesis, se buscó ajustar los datos a una regresión lineal múltiple, intentando modelar la relación lineal existente entre la glucemia y los 4 predictores. Se considerarán para esta hipótesis sólo aquellas entradas que tengan todos los valores definidos.

De ser verosímil, esperaríamos obtener un modelo significativo en su conjunto (validado mediante estadístico F) con un buen ajuste (validado mediante análisis sobre R^2). Antes de aceptar las conclusiones obtenidas, también validamos los supuestos del modelo OLS utilizado. En caso de no poder validarse los supuestos, la hipótesis se considera inconclusa.

El análisis de esta hipótesis puede encontrarse en

"4-Validación de Hipótesis"
"Multivariada"

3.6.3. Resultados obtenidos y discusión

Un ajuste inicial sobre los datos crudos dio los siguientes resultados:

```
                            OLS Regression Results
==============================================================================
Dep. Variable:     glucosa_registrada   R-squared:                       0.055
Model:                            OLS   Adj. R-squared:                  0.055
Method:                 Least Squares   F-statistic:                     73.80
Date:                Mon, 09 Nov 2026   Prob (F-statistic):           7.16e-61
Time:                        16:16:00   Log-Likelihood:                -24287.
No. Observations:                5039   AIC:                          4.858e+04
Df Residuals:                    5034   BIC:                          4.862e+04
Df Model:                           4
Covariance Type:            nonrobust
==========================================================================================
                             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                     80.7632      0.423    191.069      0.000      79.935      81.592
imc                        1.1866      0.711      1.669      0.095      -0.207       2.581
presion                    1.4912      0.491      3.039      0.002       0.529       2.453
perimetro_cintura          3.9450      0.731      5.400      0.000       2.513       5.377
edad                       2.8749      0.483      5.956      0.000       1.929       3.821
==============================================================================
Omnibus:                     2760.598   Durbin-Watson:                   1.920
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            40215.359
Skew:                           2.297   Prob(JB):                         0.00
Kurtosis:                      16.055   Cond. No.                         3.43
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Fig. 13: Resumen de resultados del modelo OLS sobre los datos sin limpieza de outliers

Análisis de resultados:

- **Significancia del modelo**: el p-valor asociado a F es bajísimo, por lo que el modelo es significativo globalmente
- **Bondad del ajuste:** R^2 es bajísimo, por lo que los puntos oscilan alrededor de la recta sin ajustarse a ella. Es señal de sospecha que un modelo que explica tan poco de la varianza de la glucosa de como significativo
- **Coeficientes:** El índice de masa corporal no es significativamente distinto de 0, por lo que podría ser descartado. El predictor más significativo es el perímetro de la cintura, seguido por la edad y por último el promedio de presión sistólica

Validación de supuestos:

- **Normalidad:** p-valores asociados a Omnibus y Jarque-Bera en 0, los residuos no se distribuyen normalmente. De skew y kurtosis podemos determinar que los residuos tienen un pico pronunciado y una cola a derecha
- **Independencia:** El test de Durbin-Watson da cercano a 2, por lo que los residuos son independientes

Otras validaciones fueron realizadas en el código, pero serán omitidas en este caso inicial porque ya tenemos supuestos invalidados y sabemos que hay outliers en los datos.

Cómo determinamos que valores extremos de glucosa generan ruido, eliminaremos los outliers y volveremos a correr la regresión. Solo se eliminan outliers en la glucemia para dejar abierta la posibilidad de que los outliers en los predictores sean realmente significativos para la glucemia. El boxplot marca como outlier aquellos valores por debajo de $Q1 - 1.5 * IQR$ o por encima de $Q3 + 1.5 * IQR$. En el caso de la glucosa, esto significa valores menores a 24.5 mg/dl o mayores a 123.5 mg/dl. Dado que los niveles de glucosa normales en ayunas están entre 70 y 100 mg/dl[1], estos límites son aceptables en términos del dominio. Volviendo a correr el modelo de regresión se obtienen los siguientes resultados:

[1] https://www.santaisabel.com.ar/santaisabel/valores-normales-de-glucemia

```
                            OLS Regression Results
==============================================================================
Dep. Variable:     glucosa_registrada   R-squared:                       0.045
Model:                            OLS   Adj. R-squared:                  0.044
Method:                 Least Squares   F-statistic:                     56.32
Date:                Mon, 09 Nov 2026   Prob (F-statistic):           1.73e-46
Time:                        11:26:21   Log-Likelihood:                -21065.
No. Observations:                4785   AIC:                         4.214e+04
Df Residuals:                    4780   BIC:                         4.217e+04
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const         77.3110      0.286    270.602      0.000      76.751      77.871
imc            0.7248      0.478      1.517      0.129      -0.212       1.662
presion       -0.1236      0.330     -0.374      0.708      -0.771       0.524
perimetro_cintura     2.7947      0.490      5.700      0.000       1.834       3.756
edad           1.8568      0.326      5.702      0.000       1.218       2.495
==============================================================================
Omnibus:                       45.774   Durbin-Watson:                   1.896
Prob(Omnibus):                  0.000   Jarque-Bera (JB):               46.971
Skew:                          -0.242   Prob(JB):                     6.32e-11
Kurtosis:                       2.954   Cond. No.                         3.40
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Fig. 14: Resumen de resultados del modelo OLS sobre los datos sin outliers en niveles de glucemia

Incluso después de eliminar los outliers de glucemia, no se cumple el supuesto de normalidad, pero vemos skew y kurtosis cercanas a los ideales, por lo que graficamos un QQ-plot y un histograma de los residuos para verificar.

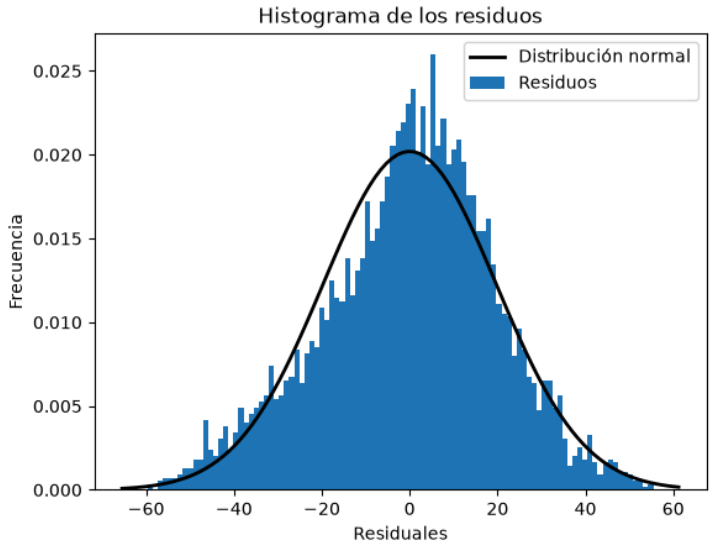


Fig. 15: Histograma de los residuos del modelo OLS sobre los datos sin outliers en niveles de glucemia

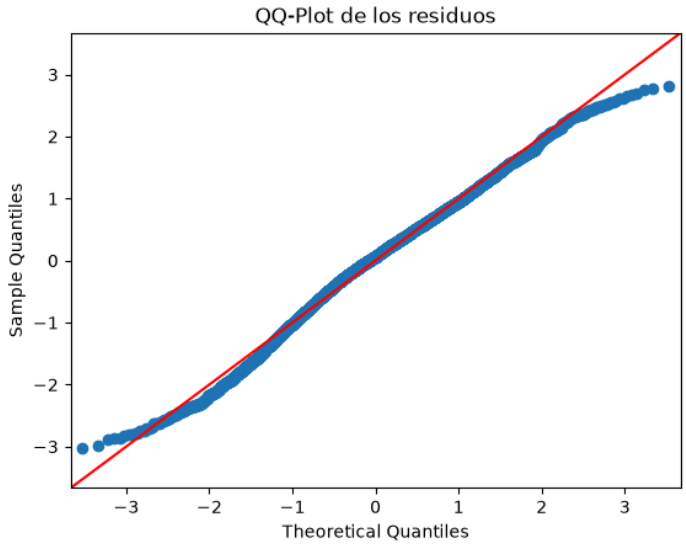


Fig. 16: QQ-Plot de los residuos del modelo OLS sobre los datos sin outliers en niveles de glucemia

Vemos que la distribución de los residuos se acerca bastante a una normal, aunque con un leve sesgo a izquierda. Aunque el test haya fallado, los tests de normalidad pueden volverse hipersensibles con tamaños de muestra tan grandes como el nuestro, por lo que podría tomarse como válido. Graficamos valores ajustados contra residuos para verificar homocedasticidad y linealidad.

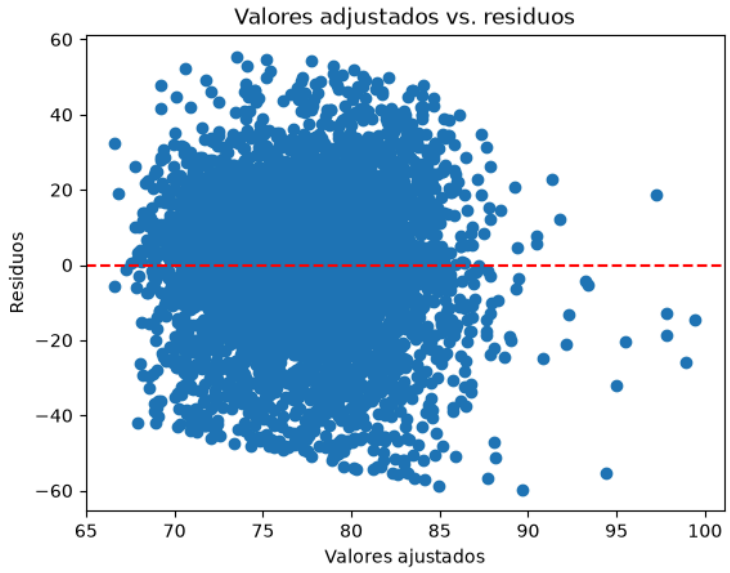
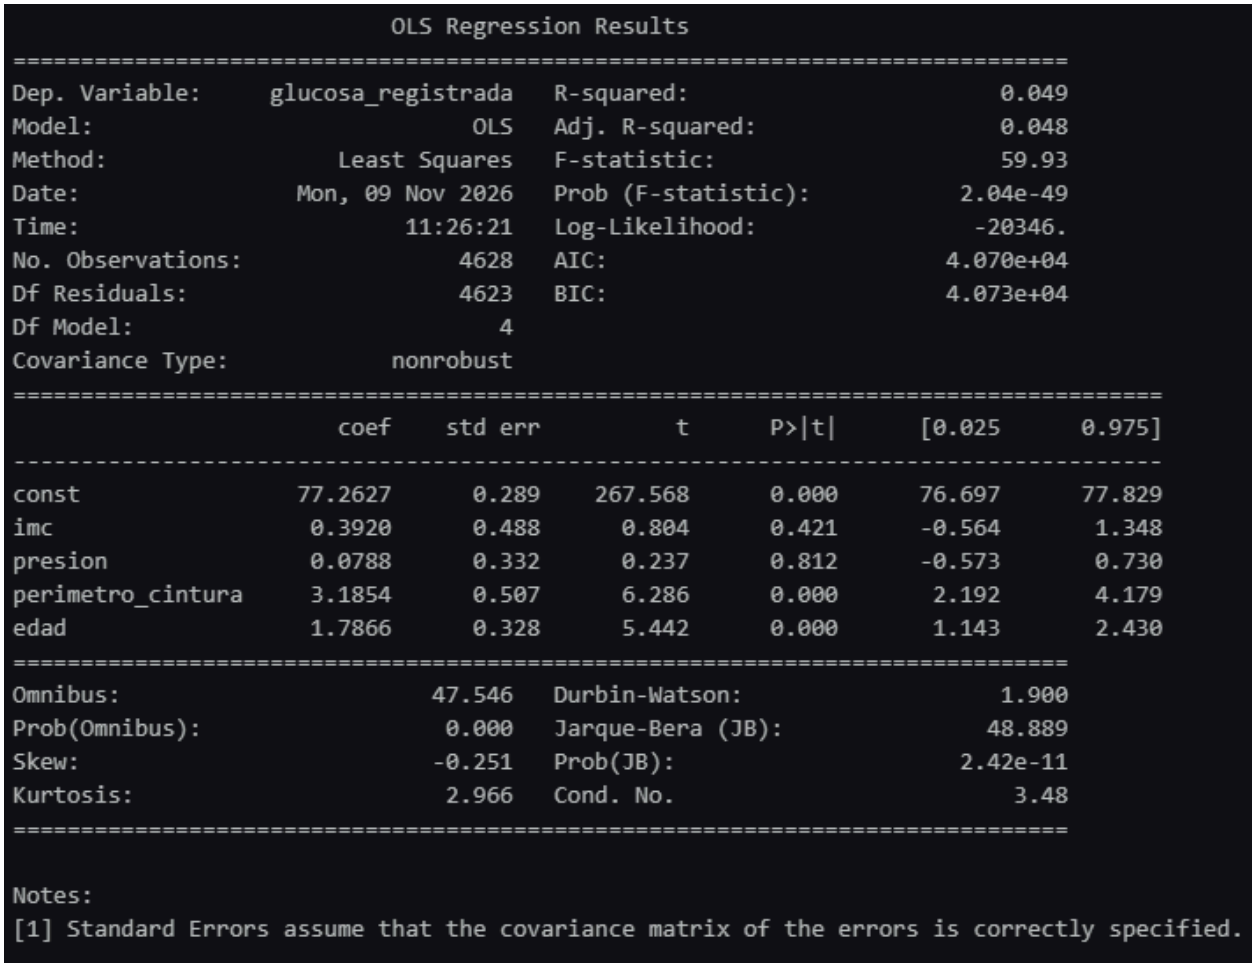


Fig. 17: Gráfico de valores ajustados vs. residuos del modelo OLS sobre los datos sin outliers en niveles de glucemia

Importante observar en este gráfico como aunque la nube de residuos sea más o menos simétrica, las diferencias entre el valor predicho y el real pueden ser de hasta 60 mg/dl por encima o por debajo, explicando el bajo ajuste del modelo.

Vemos que no hay un patrón curvo que indique no-linealidad, pero si hay un patrón en el borde inferior de la nube que parece ser una recta. Recordando que los residuos son la diferencia entre el valor real de glucemia y el valor predicho, la tendencia a valores negativos a medida que aumenta el valor ajustado indica una tendencia a sobreestimar la glucemia. Esto viola el supuesto de homocedasticidad.

Para intentar solventar la falla de este supuesto, quitamos los outliers en los predictores, con el mismo criterio a partir de los cuartiles. Estos fueron los resultados:



OLS Regression Results

Dep. Variable:	glucosa_registrada	R-squared:	0.049
Model:	OLS	Adj. R-squared:	0.048
Method:	Least Squares	F-statistic:	59.93
Date:	Mon, 09 Nov 2026	Prob (F-statistic):	2.04e-49
Time:	11:26:21	Log-Likelihood:	-20346.
No. Observations:	4628	AIC:	4.070e+04
Df Residuals:	4623	BIC:	4.073e+04
Df Model:	4		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	77.2627	0.289	267.568	0.000	76.697	77.829
imc	0.3920	0.488	0.804	0.421	-0.564	1.348
presion	0.0788	0.332	0.237	0.812	-0.573	0.730
perimetro_cintura	3.1854	0.507	6.286	0.000	2.192	4.179
edad	1.7866	0.328	5.442	0.000	1.143	2.430

Omnibus:	47.546	Durbin-Watson:	1.900
Prob(Omnibus):	0.000	Jarque-Bera (JB):	48.889
Skew:	-0.251	Prob(JB):	2.42e-11
Kurtosis:	2.966	Cond. No.	3.48

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Fig. 18: Resumen de resultados del modelo OLS sobre los datos sin outliers

Nuevamente falla el test de normalidad, así que volvemos a graficar

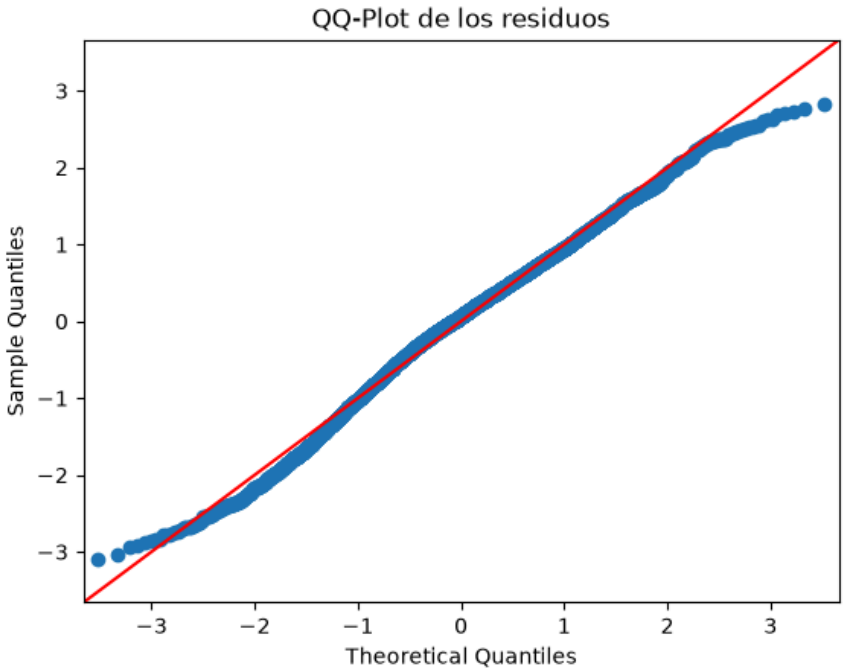


Fig. 19: QQ-Plot de los residuos del modelo OLS sobre los datos sin outliers

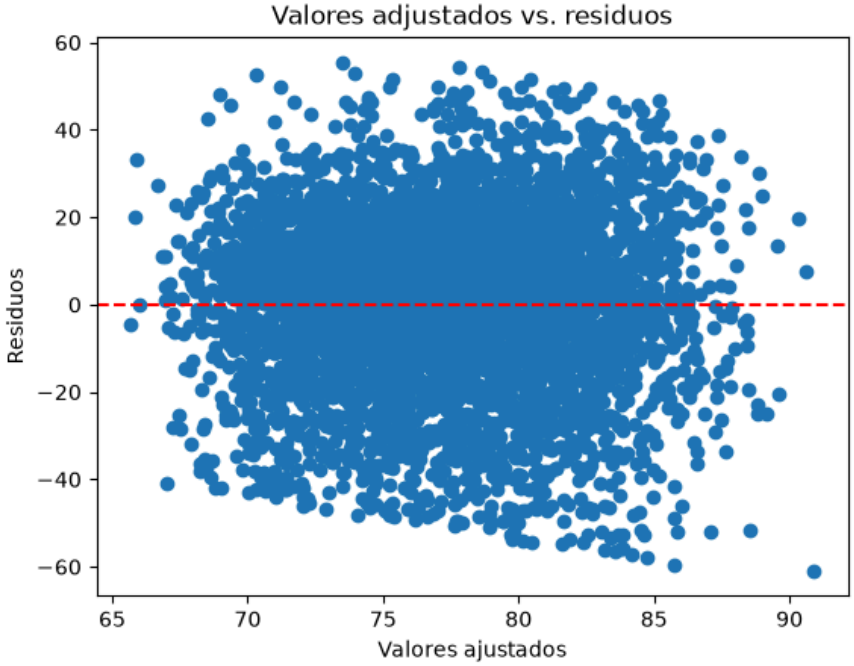


Fig. 20: Gráfico de valores ajustados vs. residuos del modelo OLS sobre los datos sin outliers

Aunque a fines prácticos podemos afirmar normalidad, sigue habiendo heterocedasticidad. En el código se probó con modelos a partir del logaritmo de la glucemia, pero ninguno fue una aproximación buena. Los modelos predicen una relación lineal significativa pero débil, pero debido al fallo de los supuestos, la hipótesis queda **inconclusa**

4. Conclusiones

Tras el análisis de las distintas hipótesis, concluimos los siguientes factores de riesgo para ciertas enfermedades no transmisibles

- **Tabaquismo:** la gran mayoría empieza en su adolescencia.
- **Obesidad, sedentarismo y nutrición:** la falta de actividad física está correlacionada con el sobrepeso, además de que la gran mayoría de la población adulta no tiene una dieta saludable en virtud del bajo consumo de frutas y verduras. Las personas con menor nivel educativo y de hogares con menores ingresos son más propensas a estos.
- **Diabetes:** no hay información suficiente para rechazar o validar que el índice de masa corporal, el ancho de la cintura, la presión sistólica y la edad se relacionan linealmente con la glucemia registrada.
- **Hipertensión:** el agregado de sal a las comidas no es un indicador directo de hipertensión.

Referencias

https://www.indec.gob.ar/ftp/cuadros/publicaciones/enfr_2018_resultados_definitivos.pdf

https://www.indec.gob.ar/ftp/cuadros/menusuperior/enfr/manual_base_usuario_enfr2018.pdf